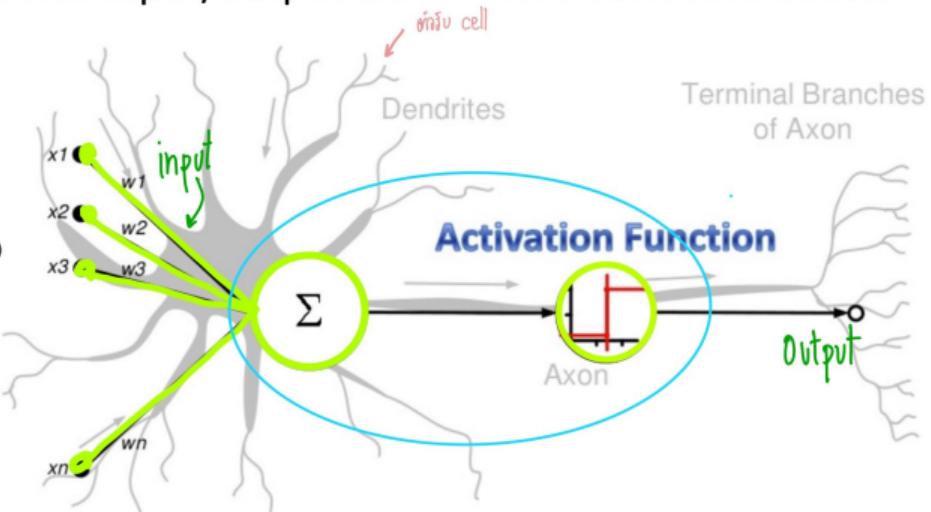


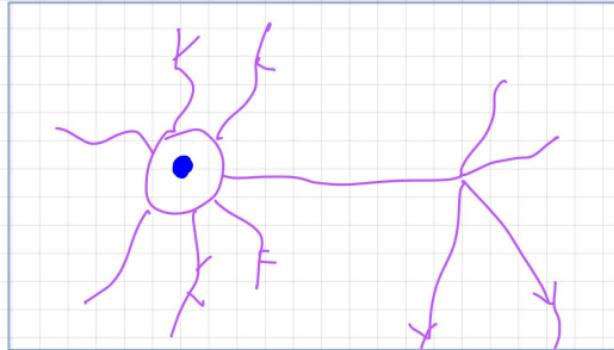
# Artificial Neural Network for Classification

एर्टिफिशियल नेयरल नेटवर्क

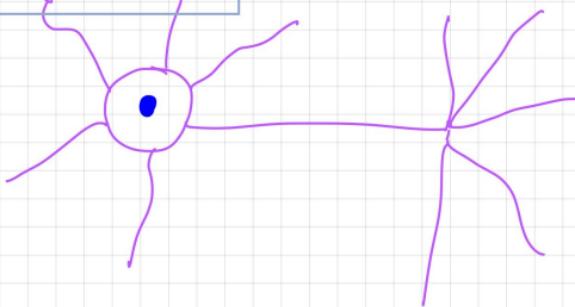
- Started by psychologists and neurobiologists to develop and test computational analogues of neurons
- A neural network: A set of connected input/output units where each connection has a **weight** associated with it
- During the learning phase, the **network learns by adjusting the weights** so as to be able to predict the correct class label of the input tuples



Artificial Neural Networks as an analogy of Biological Neural Networks

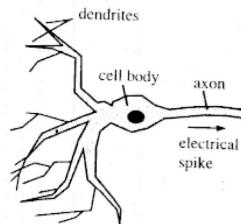


— 1 Neural



## 6.7 ข่ายงานประสาทเทียม

**ข่ายงานประสาทเทียม (Artificial Neural Network)** เป็นการจำลองการทำงานของตัวประสาทในสมองของคนเราประกอบด้วยนิวเคลียส (nucleus) ตัวเซลล์ (cell body) ไยประสาทนำเข้า (dendrite) ไยประสาทนำออก (axon) แสดงในรูปที่ 6-34

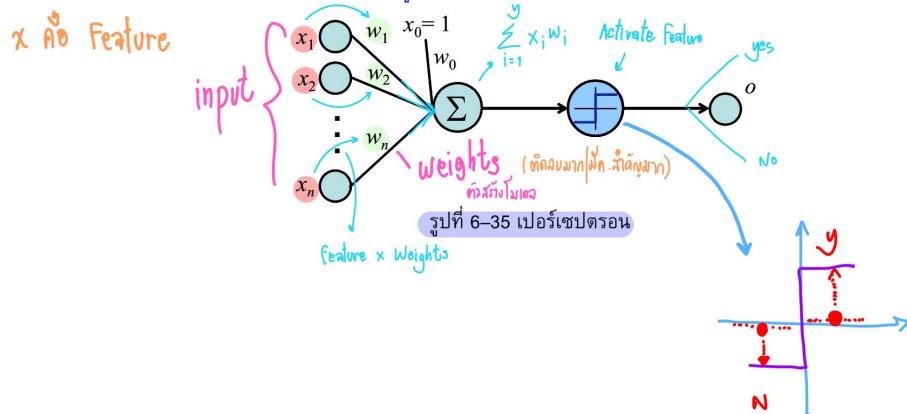


รูปที่ 6-34 เซลล์ประสาท

เดนไตร์ททำหน้าที่รับสัญญาณไฟฟ้าเคมีซึ่งส่งมาจากเซลล์ประสาทใกล้เคียง เซลล์ประสาทด้วยนั้นๆ จะเชื่อมต่อกับเซลล์ตัวอื่นๆ ประมาณ 10,000 ตัว เมื่อสัญญาณไฟฟ้าเคมีที่รับเข้ามานำเกินค่าค่าหนึ่งๆ เซลล์จะถูกกระตุ้นและส่งสัญญาณไปทางแกนประสาทน้าออกไปยังเซลล์อื่นๆ ต่อไป ประมาณกันว่าสมองของคนเรามีเซลล์ประสาทอยู่ทั้งสิ้นประมาณ  $10^{11}$  ตัว

### 6.7.1 เพอร์เซปตรอน

**เพอร์เซปตรอน (perceptron)** เป็นข่ายงานประสาทเทียมแบบง่ายมีหน่วยเดียวที่จำลองลักษณะของเซลล์ประสาทดังรูปที่ 6-35



เพอร์เซปตรอนรับอินพุตเป็นเวกเตอร์จำนวนจริงแล้วคำนวนผลรวมเชิงเส้น (linear combination) แบบถ่วงน้ำหนักของอินพุต ( $x_1, x_2, \dots, x_n$ ) โดยที่ค่า  $w_1, w_2, \dots, w_n$  ในสูตรเป็นค่าน้ำหนักของอินพุตและให้อาร์พุต ( $\sigma$ ) เป็น 1 ถ้าผลรวมที่ได้มีค่าเกินค่าขีดแบ่ง ( $\theta$ ) และเป็น -1 ถ้าไม่เกิน ส่วน  $w_0$  ในสูตรเป็นค่าบานของค่าขีดแบ่งดังจะได้อธิบายต่อไป และ  $x_0$  เป็นอินพุตเพิ่มกำหนดให้มีค่าเป็น 1 เสมอ



พังก์ชันgradeต้น

ในรูปแสดงพังก์ชันgradeต้น (activation function) ชนิดที่เรียกว่าพังก์ชันสองขั้ว (bipolar function) ซึ่งแสดงผลของอาร์พุตเป็น 1 กับ -1 พังก์ชันgradeต้นอื่นๆ ที่นิยมใช้ก็อย่างเช่น พังก์ชันไบนาเรีย (binary function) ซึ่งแสดงผลของอาร์พุตเป็น 1 กับ 0 และเขียน



แทนด้วยรูป

เราสามารถแสดงอาร์พุต ( $\sigma$ ) ในรูปของพังก์ชันของอินพุต ( $x_1, x_2, \dots, x_n$ ) ได้ดังนี้

$$o(x_1, x_2, \dots, x_n) = \begin{cases} 1 & \text{if } w_1x_1 + w_2x_2 + \dots + w_nx_n \geq \theta \\ -1 & \text{if } w_1x_1 + w_2x_2 + \dots + w_nx_n < \theta \end{cases} \quad (6.7)$$

อาร์พุตเป็นพังก์ชันของอินพุตในรูปของผลรวมเชิงเส้นแบบถ่วงน้ำหนัก น้ำหนักจะเป็นตัวกำหนดว่าในจำนวนอินพุตไหน อินพุต ( $x_i$ ) ตัวใดมีความสำคัญต่อการกำหนดค่าอาร์พุต ตัวที่มีความสำคัญมากจะมีค่าสัมบูรณ์ของน้ำหนักมาก ส่วนตัวที่มีความสำคัญน้อยจะมีค่าใกล้ศูนย์ ในการถือที่ผลรวมเท่ากับค่าขีดแบ่งค่าอาร์พุตไม่泥ิยาน (จะเป็น 1 หรือ -1 ก็ได้)

จากพังก์ชันในสูตรที่ (6.7) เราจัดรูปใหม่โดยย้าย  $\theta$  ไปรวมกับผลรวมเชิงเส้นแล้วแทน  $-\theta$  ด้วย  $w_0$  เราจะได้พังก์ชันของอาร์พุตดังด้านล่างนี้

$$o(x_1, x_2, \dots, x_n) = \begin{cases} 1 & \text{if } w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n > 0 \\ -1 & \text{if } w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n < 0 \end{cases} \quad (6.8)$$

กำหนดให้  $g(\vec{x}) = \sum_{i=0}^n w_i x_i = \vec{w} \cdot \vec{x}$  โดยที่  $\vec{x}$  แทนเวกเตอร์อินพุต เราสามารถเขียน

พังก์ชันของอาร์พุตได้ใหม่ดังนี้

$$o(x_1, x_2, \dots, x_n) = \begin{cases} 1 & \text{if } g(\vec{x}) > 0 \\ -1 & \text{if } g(\vec{x}) < 0 \end{cases} \quad (6.9)$$

สมมติว่าเรามีอินพุตสองตัวคือ  $x_1$  และ  $x_2$  ซึ่งแสดงค่าล่วงสูงและน้ำหนักของเด็กนักเรียน ประจุและหลังจากที่แพทฟอร์มตรวจร่างกายของเด็กโดยละเอียดแล้วได้จำแนกนักเรียน

ออกแบบส่องกลุ่มคือเด็กอ้วนและเด็กไม่อ้วน เราให้อาตพุตเป็นค่าที่แสดงเด็กอ้วนแทนด้วย +1 กับไม่อ้วนแทนด้วย -1 ดังตารางที่ 6-16

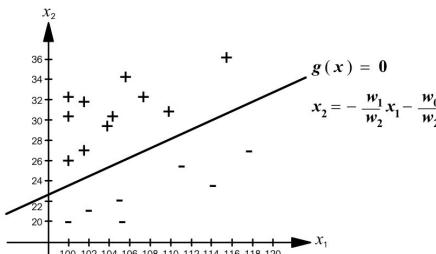
ตารางที่ 6-16 ข้อมูลเด็กอ้วนและเด็กไม่อ้วน

เด็กคนที่	ส่วนสูง (ซม.)	น้ำหนัก (กг.)	อ้วน/ไม่อ้วน
1	100.0	20.0	-1
2	100.0	26.0	1
3	100.0	30.4	1
4	100.0	32.4	1
5	101.6	27.0	1
6	101.6	32.0	1
7	102.0	21.0	-1
8	103.6	29.6	1
9	104.4	30.4	1
10	104.9	22.0	-1
11	105.2	20.0	-1
12	105.6	34.4	1
13	107.2	32.4	1
14	109.9	34.9	1
15	111.0	25.4	-1
16	114.2	23.5	-1
17	115.5	36.3	1
18	117.8	26.9	-1

ในการสมที่มีอินพุต 2 ตัว (ไม่รวม  $x_0$ ) เราจะได้  $g(\vec{x}) = w_0 + w_1x_1 + w_2x_2$  ซึ่งถ้าเราให้  $g(\vec{x}) = 0$  จะได้ว่า  $w_0 + w_1x_1 + w_2x_2 = 0$  ซึ่งแทนสมการเส้นตรงในระบบสองมิติ  $x_1$ ,

$x_2$  สมการนี้มีจุดตัดแกนอยู่ที่  $-\frac{w_0}{w_2}$  และมีความชันเท่ากับ  $-\frac{w_1}{w_2}$  เมื่อนำสมการนี้ไปวัดใน

ระบบสองมิติร่วมกับตัวอย่างสอนในตารางที่ 6-16 โดยกำหนดค่า  $w_0$ ,  $w_1$ ,  $w_2$  ที่เหมาะสมจะได้ดังรูปที่ 6-36



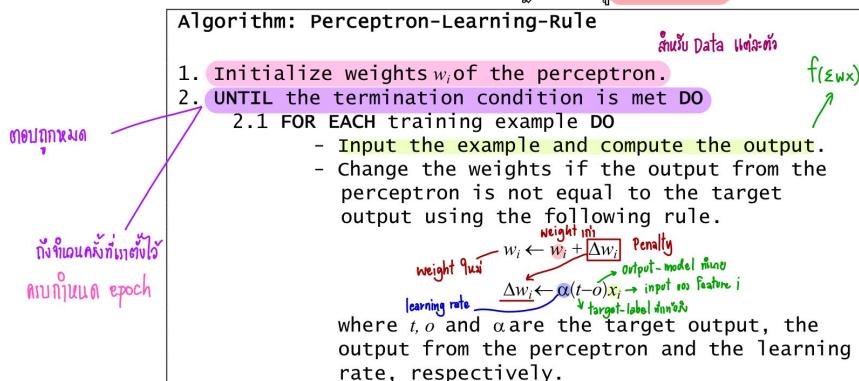
ຮູບທີ 6–36 ສາມກາຣັນດຽວສ້າງໂພຣ໌ເຫັນຕອນ

ເຄື່ອງໝາຍ + ແລະ - ໃນຮູປແກນດ້ວຍຢ່າງນວກ (ເຕັກວ້ານ) ແລະດ້ວຍຢ່າງລົບ (ເຕັກໄໝວ້ານ) ຕາມສຳດັບ ດັ່ງເທິ່ງໄດ້ໃນຮູປວ່າເສັນດຽວນີ້ມີການຫຼຸດຕັດແກນແລະຄວາມຂັ້ນທີ່ເໝາະສົມສົ່ງ ກໍາຫັດໂດຍ  $w_0$ ,  $w_1$ ,  $w_2$  ເສັນດຽວນີ້ຈະແປ່ງດ້ວຍຢ່າງອອກເປັນສອງຄຸນໆທີ່ອູ້ຄຸນລະດ້ານຂອງ ເສັນດຽວ ແລະເມື່ອມີຂໍ້ມູນລວມສູງແລະນ້າໜັກຂອງເຕັກຄົນອື່ນທີ່ເຮົາດ້ວຍການທຳນາຍວ່າຈະເປັນເກົກ ວ້ານໂໝ່ໄໝວ້າ ກີ່ໃຊ້ເສັນດຽວນີ້ໄດ້ຢູ່ວ່າຂໍ້ມູນໄໝ້ດ້ານໃຂອງເສັນດຽວ ຄ້າດ້ານບັນກິທຳນາຍວ່າ ເປັນເຕັກວ້ານ (+) ຄ້າດ້ານລ່າງກີທຳນາຍວ່າເຕັກໄໝວ້ານ (-)

ດ້ວຍຢ່າງດ້ານນັ້ນແສດງການນີ້ຂອງອິນຝຸດໃນສອງມິຕີ ຈະເຫັນໄດ້ວ່າເພອຣ໌ເຫັນຕອນຈະເປັນ ເສັນດຽວ ໃນການນີ້ທີ່ອິນຝຸດມາກວ່າສອງມິຕີເພອຣ໌ເຫັນຕອນຈະເປັນ **ຮະນາບັດດ້າລິນໃຫ້ຫລາຍມິຕີ** (*hyperplane decision surface*) ບັນຍາກາຮົງເຮັນຮູ້ເພອຣ໌ເຫັນຕອນກີ່ກ່ອງກາຫາຄ່າເວັກເຕັກ ນ້າໜັກ (p) ທີ່ແໜ່ສສົນໃນກາຈຳນາແກ່ເກົ່າຂອງຂໍ້ມູນສອນພໍອໃຫ້ເພອຣ໌ເຫັນຕອນແສດງ ເຄົດພຸດໄດ້ຮັງກັນຄໍາທີ່ສອນ **ກົງກາຮົງເຮັນຮູ້ເພອຣ໌ເຫັນຕອນ** (*perceptron learning rule*) ໃຊ້ ສ້າງສັນພອຣ໌ເຫັນຕອນໂດຍຈະຫາຄ່າເວັກເຕັກນ້າໜັກດັ່ງແສດງໃນຕາງໆທີ່ 6–17

ອັລກອົບໃກ່ມີເຮັດວຽກຈຳກັດຈຳກ່າວເຕັກນ້າໜັກ ສື່ໂດຍມາກຄ່າທີ່ສຸມນາຈະໄມ້ໄດ້ຮະນາບ ພ່າຍມິຕີທີ່ແປ່ງດ້ວຍຢ່າງໄດ້ຄູກທ້ອງຖຸກດ້ວຍດັ່ງນັ້ນຈຶ່ງທີ່ມີການແກ້ໄຂນ້າໜັກໂດຍເຫັນເພອຣ໌ເຫັນຕອນກັບດ້ວຍຢ່າງທີ່ສອນ ຮ່າມຍົງວ່າເມື່ອເວົ້າປັນດ້ວຍຢ່າງສອນເຂົ້າໄປໃນເພອຣ໌ເຫັນຕອນ ເຮົາຈະຄ່າວຸນຄໍາເຄາະຕົກພຸດໄດ້ ນ້າຄ່າເຄາະຕົກພຸດທີ່ຄ່າວຸນໄດ້ໂດຍເພອຣ໌ເຫັນຕອນເຫັນຕົກ ເຄາະຕົກເປົ້າໝາຍ ຄ້າດ້ານນັ້ນແສດງວ່າຈຳນາແກ່ດ້ວຍຢ່າງໄດ້ຄູກຕ້ອງ ໄມ່ດ້ວຍປັບນ້າໜັກລຳຫຽບ ດ້ວຍຢ່າງນັ້ນ ແຕ່ກໍາໄໝມີຕຽງກັນກີ່ກ່ອງກາປັບນ້າໜັກດາມສົມການໃນອັລກອົບໃກ່ມີ ສ່ວນອັດຕະກາຮົງ ເຮັນຮູ້ເປັນຕົວເລີຂວາງຈຳນານັ້ນອໍາງ ເຊັ່ນ 0.01, 0.005 ເປັນຕົ້ນ ອັດຕະກາຮົງເຮັນຮູ້ນີ້ຈະໜ່າງລົບຕ່ອງກັນ ການສູ້ເຂົ້າຂອງເພອຣ໌ເຫັນຕອນ ຄ້າອັດຕະກາຮົງເຮັນຮູ້ມີຄໍານາພົບຕົກກີ່ຈະເຮັນຮູ້ໄດ້ເວົາ ແຕ່ກີ່ຈະເຮັນຮູ້ໄດ້ສໍາເລັດເນື່ອຈາກການປັບປຸງຕ່າງໆ ມີຄວາມຫຍານເກີນໄປ ອັດຕະກາຮົງເຮັນຮູ້ທີ່ມີຄ່າ ນ້ອຍກົຈະກ່າວໃຫ້ການປັບນ້າໜັກກໍາໄໝດ້ວຍຢ່າງລະເຍີດແຕ່ກີ່ຈະເສີ່ງເລາໃນກາຮົງວັນ

ตารางที่ 6-17 อัลกอริทึมกฎการเรียนรู้เพอร์เซปตอรอน



การปรับน้ำหนักตามกฎการเรียนรู้เพอร์เซปตอรอนโดยใช้อัตราการเรียนรู้ที่มีค่าน้อยเพียงพอ จะได้รับ nab หมายมิติที่จะสู่เข้าสู่ระบบหนึ่งที่สามารถแปลงข้อมูลออกเป็นสองส่วน (ในกรณีที่ข้อมูลสามารถแบ่งได้) เพื่อเชิงข่ายผลที่เกิดจากการปรับค่าน้ำหนัก เราจะลองพิจารณาดูตัวอย่างของกฎการเรียนรู้นี้ว่าทำไงการปรับน้ำหนักเข่นนี้จะสู่เข้าสู่ระบบหนึ่งที่แบ่งข้อมูลได้อย่างถูกต้อง

- พิจารณากรณีแรกที่เพอร์เซปตอรอนแยกตัวอย่างสองด้านที่ที่รับเข้ามาได้ถูกต้องกรณีนี้จะพบว่า  $(t-o)$  จะมีค่าเป็น 0 ดังนั้น  $\Delta w_i$  ไม่เปลี่ยนแปลง เพราะ  $\Delta w_i = \alpha(t-o)x_i$
- พิจารณาในกรณีที่เพอร์เซปตอรอนให้อาดัตพุดเป็น -1 แต่อาดัตพุดเป้าหมายหรือค่าที่แท้จริงเท่ากับ 1 ในกรณีนี้หมายความว่าค่าที่เราต้องการคือ 1 แต่ค่าน้ำหนักไม่เหมาะสม ดังนั้นเพื่อที่จะทำให้เพอร์เซปตอรอนให้อาดัตพุดเป็น 1 น้ำหนักต้องถูกปรับให้สามารถเพิ่มค่าของ พ. x ในกรณีนี้หมายความว่าผลรวมเชิงเส้นน้อยเกินไปและน้อยกว่า 0 จึงได้อาดัตพุดเป็น -1 ดังนั้นสิ่งที่เราต้องการคือการเพิ่มค่าผลรวมเชิงเส้นเพิ่มค่าให้เรื่อยๆ จนมากกว่า 0 เพอร์เซปตอรอนจะให้อาดัตพุดเป็น 1 ซึ่งตรงกับที่เราต้องการ พิจารณาดูดังต่อไปนี้ว่าการปรับค่าโดยกฎเรียนรู้ทำให้ผลรวมเชิงเส้นเพิ่มขึ้นได้อย่างไร กรณีนี้เราจะได้ว่า  $(t-o)$  เท่ากับ  $(1-(-1))$  มีค่าเป็น 2 และลองพิจารณาค่าของอินพุต  $x_i$  และกรณีดังนี้

- ถ้า  $x_i > 0$  จะได้ว่า  $\Delta w_i$  มากกว่า 0 เพราะว่า  $\Delta w_i \leftarrow \alpha(t-o)x_i$  และ  $\alpha$  มากกว่า 0,  $(t-o) = 2$  และ  $x_i > 0$  จากสมการการปรับน้ำหนัก  $w_i \leftarrow w_i + \Delta w_i$  เมื่อ  $\Delta w_i$  มากกว่า 0 จะทำให้  $w_i$  มีค่าเพิ่มขึ้นและ  $\sum w_i x_i$  ก็จะมีค่าเพิ่มขึ้น เมื่อผลรวมมีค่ามากขึ้นแสดงว่าการปรับไปในทิศทางที่ถูกต้องคือเมื่อปรับไปจนกระทั่งได้ผลรวมมากกว่า 0 จะทำให้เพอร์เซปตรอนเอาร์พุตได้ถูกต้องยิ่งขึ้น
- ถ้า  $x_i < 0$  เราจะได้ว่า  $\alpha(t-o)x_i$  จะมีค่าน้อยกว่า 0 แสดงว่า  $w_i$  ตัวที่คุณกับ  $x_i$  ที่น้อยกว่า 0 จะลดลงทำให้  $\sum w_i x_i$  เพิ่มขึ้นเหมือนเดิม เพราะ  $x_i$  เป็นค่าลบและ  $w_i$  มีค่าลดลง ในที่สุดก็จะทำให้เพอร์เซปตรอนให้เอาร์พุตได้ถูกต้องยิ่งขึ้น
- ในกรณีที่เพอร์เซปตรอนให้เอาร์พุตเป็น 1 แต่เอาร์พุตเป้าหมายหรือค่าที่แท้จริงเท่ากับ -1 จะได้ว่า  $w_i$  ของ  $x_i$  ที่เป็นค่าลบลดลง ส่วน  $w_i$  ของ  $x_i$  ที่เป็นค่าลบจะเพิ่มขึ้นและทำให้การปรับเป็นไปในทิศทางที่ถูกต้องเช่นเดียวกับในการนี้แรก

### 6.7.2 ตัวอย่างการเรียนฟังก์ชัน AND และ XOR ด้วยกฎเรียนรู้เพอร์เซปตรอน

พิจารณาตัวอย่างการเรียนรู้ของเพอร์เซปตรอนโดยจะให้เรียนรู้ฟังก์ชัน 2 ฟังก์ชัน ฟังก์ชัน XOR คือฟังก์ชัน AND และในตารางที่ 6-18 ในการนี้เรายังคงใช้ฟังก์ชัน AND ในการเรียนรู้เพอร์เซปตรอนนี้

ตารางที่ 6-18 ฟังก์ชัน AND( $x_1, x_2$ )

$x_1$	$x_2$	เอาร์พุต เป้าหมาย
0	0	0
0	1	0
1	0	0
1	1	1

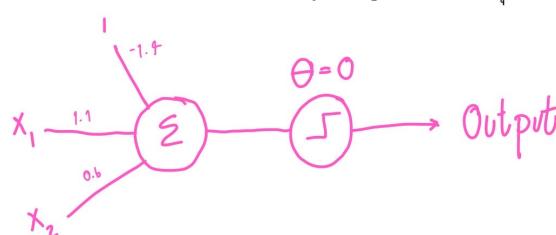
$$\begin{aligned} T \wedge T &\equiv T \\ T \wedge F &\equiv F \\ F \wedge T &\equiv F \\ F \wedge F &\equiv F \end{aligned}$$

ฟังก์ชัน AND ตามตารางด้านบนนี้จะให้ค่าที่เป็นจริงถ้าต่อเมื่อ  $x_1$  และ  $x_2$  เป็นจริงทั้งคู่ (ถ้าที่สุดมก.เอาร์พุตเป้าหมาย) ผลการใช้กฎการเรียนรู้เพอร์เซปตรอนกับฟังก์ชัน AND และในตารางที่ 6-19

# ข้อสอบ ค้อ เต็มตราวิ่ง

ตารางที่ 6-19 ผลการเรียนรู้ฟังก์ชัน AND โดยกฎการเรียนรู้เพอร์เซปตรอน

ขั้นตอนแรกเริ่มจากการสูมค่า  $w_0$  จากนั้น  $w_2$  ในที่นี้กำหนดให้เป็น 0.1 ทั้งสามตัว จากนั้นก็เริ่มป้อนตัวอย่างเข้าไป (ทีละacco) ตัวอย่างแรกได้ผลรวมเชิงเส้น (Net Sum) เป็น 0.10 ซึ่งมากกว่า 0 ดังนั้นเปอร์เซปตรอนจะให้ออกมาเป็น 1 ซึ่งผิด เพราะเอาต์พุตเดียวหมาย (Target Output) จะต้องได้เป็น 0 ทำให้ตัวการเรียนรู้คูณค่าผิดพลาด ( $\text{Alpha} \times \text{Error}$ ) ได้  $-0.50$  หลังจากนั้นนำไปปรับน้ำหนักตาม  $w_i \leftarrow w_i + \Delta w_i$  และ  $\Delta w_i \leftarrow \alpha(t-o)x_i$ ; ดังนั้นจะได้เป็น  $w_0 \leftarrow w_0 + \alpha(t-o)x_0 = w_0 + 0.50(-1) \times 1 = 0.10 + (-0.5) = -0.4$  ต่อไปก็ปรับค่า  $w_1$  ในทำนองเดียวกัน  $w_1 \leftarrow w_1 + \alpha(t-o)x_1 = w_1 + 0.50(-1) \times 0$  ดังนั้น  $w_1$  จะเท่ากับ 0.10 คือไม่เปลี่ยนแปลง เช่นเดียวกับ  $w_2$  ที่ไม่เปลี่ยนแปลง จะเห็นได้ว่าแม้เมื่อค่าผิดพลาดแตกต่างกับการปรับค่า  $w_1$  และ  $w_2$  เนื่องจากอินพุตที่ใส่เข้าไปเป็น 0 ทำ



# **Chapter 8. Classification: Basic Concepts**

---

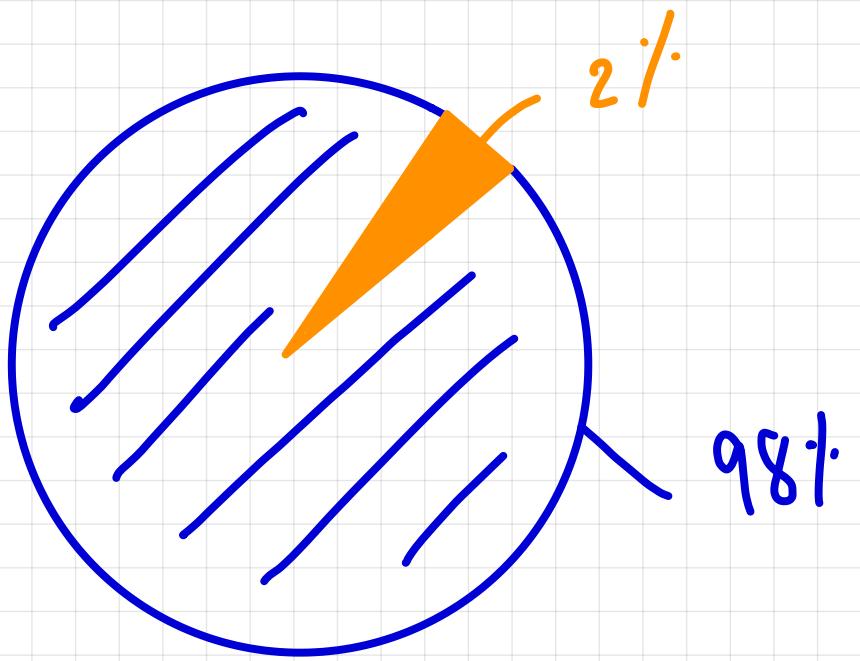
- ❑ Classification: Basic Concepts
- ❑ Decision Tree Induction
- ❑ Bayes Classification Methods
- ❑ Linear Classifier
- ❑ Model Evaluation and Selection
- ❑ Techniques to Improve Classification Accuracy: Ensemble Methods
- ❑ Additional Concepts on Classification
- ❑ Summary



# Model Evaluation and Selection

---

- Evaluation metrics
  - How can we measure accuracy?
  - Other metrics to consider?
- Use **validation test set** of class-labeled tuples instead of training set when assessing accuracy
- Methods for estimating a classifier's accuracy
  - Holdout method
  - Cross-validation
  - Bootstrap
- Comparing classifiers:
  - ROC Curves



Classifier → ၂မျှ၏။

98%

# Classifier Evaluation Metrics: Confusion Matrix

- **Confusion Matrix:**

Actual class \ Predicted class	$C_1$	$\neg C_1$
$C_1$	True Positives (TP)	False Negatives (FN)
$\neg C_1$	False Positives (FP)	True Negatives (TN)

Precision

Recall

- In a confusion matrix w.  $m$  classes,  $CM_{i,j}$  indicates # of tuples in class  $i$  that were labeled by the classifier as class  $j$

- May have extra rows/columns to provide totals

- **Example of Confusion Matrix:**

Actual class \ Predicted class	buy_computer = yes	buy_computer = no	Total
buy_computer = yes	6954	46	7000
buy_computer = no	412	2588	3000
Total	7366	2634	10000

test / positive / negative

Positive

Negative

# Classifier Evaluation Metrics: Accuracy, Error Rate, Sensitivity and Specificity

---

A\P	C	$\neg C$	
C	TP	FN	P
$\neg C$	FP	TN	N
	P'	N'	All

- Classifier accuracy, or recognition rate
  - Percentage of test set tuples that are correctly classified
- **Accuracy** =  $(TP + TN)/All$
- Error rate:  $1 - accuracy$ , or  
 $Error rate = (FP + FN)/All$

- Class imbalance problem
  - One class may be *rare*
    - E.g., fraud, or HIV-positive
  - Significant *majority of the negative class* and minority of the positive class
  - Measures handle the class imbalance problem
- **Sensitivity** (recall): True positive recognition rate
  - **Sensitivity** =  $TP/P$
- **Specificity**: True negative recognition rate
  - **Specificity** =  $TN/N$

# Classifier Evaluation Metrics: Precision and Recall, and F-measures

- **Precision:** Exactness: what % of tuples that the classifier labeled as positive are actually positive?

$$P = \text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

ຕົກ່ານ Model ມະນີ້ນ Positive  
ດູວ່າມານັກິນ

- **Recall:** Completeness: what % of positive tuples did the classifier label as positive?

$$R = \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Model ເຮັດຕົກ່ານ Positive ອົງໝາຍ  
ອົກ - ເປົ້າ ໄດ້ໃຫຍ່

- Range: [0, 1]
- The “inverse” relationship between precision & recall
- **F measure (or F-score):** harmonic mean of precision and recall
- In general, it is the weighted measure of precision & recall

$$F_{\beta} = \frac{1}{\alpha \cdot \frac{1}{P} + (1 - \alpha) \cdot \frac{1}{R}} = \frac{(\beta^2 + 1)PR}{\beta^2 P + R}$$

Assigning  $\beta$  times as much weight to recall as to precision)

- **F1-measure (balanced F-measure)**

- That is, when  $\beta = 1$ ,

$$F_1 = \frac{2PR}{P + R}$$

F<sub>1</sub> ສູງສົດ  
F<sub>1</sub> ຖໍ່ໄມ້ດັກ } ຕ້ອງກູ້ທີ່ຈະຮັກນີ້